Random Forest Python Tutorial

Digits dataset from sklearn

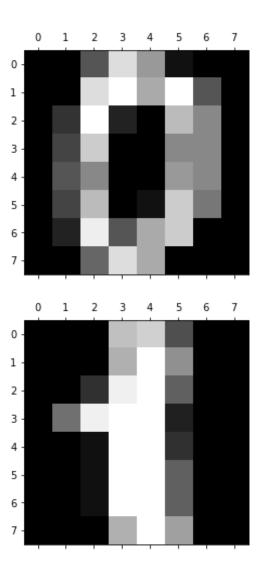
```
In [6]: import pandas as pd
    from sklearn.datasets import load_digits
digits = load_digits()

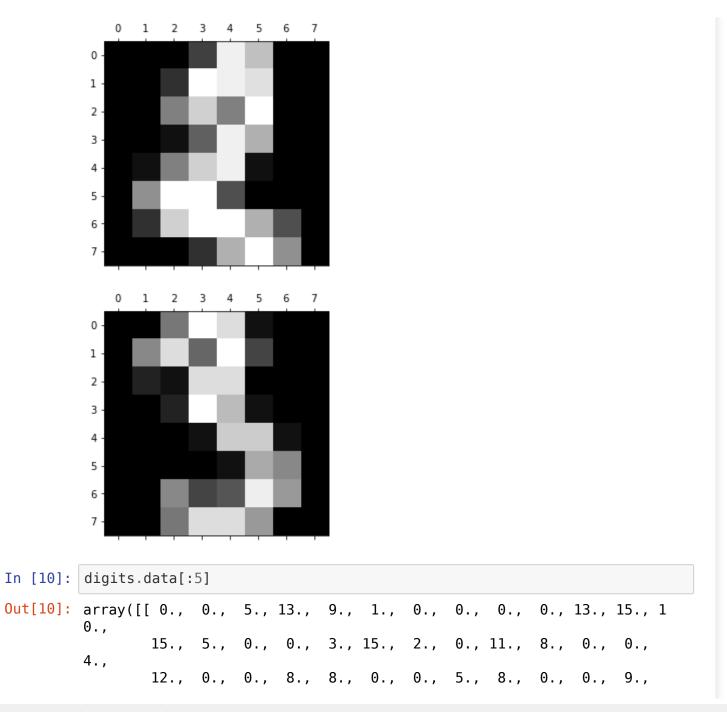
In [7]: dir(digits)

Out[7]: ['DESCR', 'data', 'images', 'target', 'target_names']

In [9]: %matplotlib inline
    import matplotlib.pyplot as plt
    plt.gray()
    for i in range(4):
        plt.matshow(digits.images[i])

<Figure size 432x288 with 0 Axes>
```



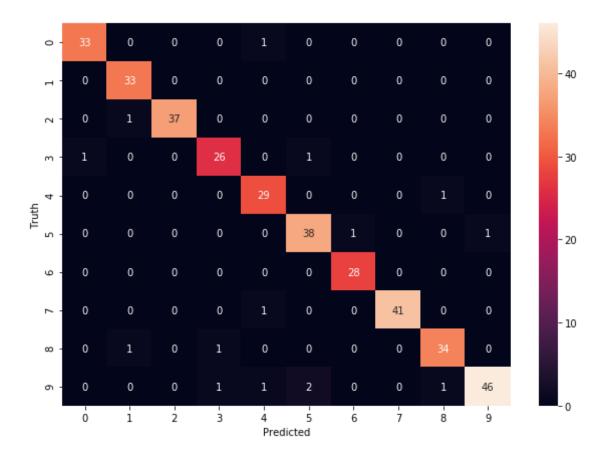


```
8.,
       0., 0., 4., 11., 0., 1., 12., 7., 0., 0., 2., 14.,
5.,
       10., 12., 0., 0., 0., 0., 6., 13., 10., 0., 0., 0.]
      [0., 0., 0., 12., 13., 5., 0., 0., 0., 0., 0., 11., 1]
6.,
       9., 0., 0., 0., 0., 3., 15., 16., 6., 0., 0., 0.,
7.,
       15., 16., 16., 2., 0., 0., 0., 0., 1., 16., 16., 3.,
0.,
       0., 0., 0., 1., 16., 16., 6., 0., 0., 0., 0., 1., 1
6.,
       16., 6., 0., 0., 0., 0., 11., 16., 10., 0., 0.],
      [0., 0., 0., 4., 15., 12., 0., 0., 0., 0., 3., 16., 1]
5.,
       14., 0., 0., 0., 0., 8., 13., 8., 16., 0., 0.,
0.,
       1., 6., 15., 11., 0., 0., 0., 1., 8., 13., 15., 1.,
0.,
       0., 0., 9., 16., 16., 5., 0., 0., 0., 0., 3., 13., 1
6.,
       16., 11., 5., 0., 0., 0., 3., 11., 16., 9., 0.],
      [0., 0., 7., 15., 13., 1., 0., 0., 0., 8., 13., 6., 1]
5.,
       4., 0., 0., 0., 2., 1., 13., 13., 0., 0., 0., 0.,
0.,
       2., 15., 11., 1., 0., 0., 0., 0., 0., 1., 12., 12.,
1.,
       0., 0., 0., 0., 1., 10., 8., 0., 0., 8.,
4.,
        5., 14., 9., 0., 0., 0., 7., 13., 13., 9., 0., 0.
      [0., 0., 0., 1., 11., 0., 0., 0., 0., 0., 0., 7.,
8.,
       0., 0., 0., 0., 1., 13., 6., 2., 2., 0., 0.,
0.,
       7., 15., 0., 9., 8., 0., 0., 5., 16., 10., 0., 16.,
6.,
       0., 0., 4., 15., 16., 13., 16., 1., 0., 0., 0., 0.,
```

```
3.,
            15., 10., 0., 0., 0., 0., 0., 2., 16., 4., 0., 0.]
In [11]: df = pd.DataFrame(digits.data)
      df.head()
Out[11]:
         0
            1
                                  9 ... 54 55 56
                                             57
                                                58
                                                         61
       0 0.0 0.0 5.0 13.0
                    9.0
                       1 0.0 0.0 0.0 12.0
                   13.0
                   3 0.0 0.0 7.0 15.0 13.0
                       1.0 0.0 0.0 0.0 8.0 ... 9.0 0.0 0.0 0.0 7.0 13.0 13.0
                       4 0.0 0.0 0.0
                1.0 11.0
      5 rows × 64 columns
In [12]: df['target']=digits.target
      df.head()
Out[12]:
                                  9 ... 55 56
                                                         62
       0 0.0 0.0 5.0 13.0
                    9.0
                       1.0 0.0 0.0 0.0 0.0 ... 0.0 0.0 0.0 6.0 13.0 10.0
                       1 0.0 0.0 0.0 12.0
                   13.0
       3 0.0 0.0 7.0 15.0 13.0
                       1.0 0.0 0.0 0.0 8.0 ... 0.0 0.0 0.0 7.0 13.0 13.0
                                                      9.0 0.0
       4 0.0 0.0 0.0 1.0 11.0
                       5 rows × 65 columns
In [32]: from sklearn.model selection import train test split
      X train,X test,y train,y test = train test split(df.drop(['target'],axi
```

```
s='columns'), digits.target, test size=0.2)
In [33]: len(X train)
Out[33]: 1437
In [34]: len(X test)
Out[34]: 360
In [35]: from sklearn.ensemble import RandomForestClassifier
         model = RandomForestClassifier(n estimators=40)
         model.fit(X train, y train)
Out[35]: RandomForestClassifier(bootstrap=True, ccp alpha=0.0, class weight=Non
         e,
                                 criterion='gini', max depth=None, max features
         ='auto',
                                 max leaf nodes=None, max samples=None,
                                 min impurity decrease=0.0, min impurity split=No
         ne,
                                 min samples leaf=1, min samples split=2,
                                 min weight fraction leaf=0.0, n estimators=40,
                                 n jobs=None, oob score=False, random state=None,
                                 verbose=0, warm start=False)
In [36]: model.score(X test,y test)
Out[36]: 0.95833333333333334
In [37]: y predicted = model.predict(X test)
         Confusion Matrix
In [42]: from sklearn.metrics import confusion matrix
         cm = confusion matrix(y test, y predicted)
         \mathsf{cm}
```

```
Out[42]: array([[33, 0, 0, 0, 1, 0, 0,
                                             0, 0],
              [ 0, 33,
                       Θ,
                           0,
                                      0,
                                             0, 0],
              [ 0, 1, 37, 0,
                                                0],
                       0, 26,
                                             0, 0],
                           0, 29,
                                  0,
                                                0],
                       0, 0,
                              0, 38, 1,
                                             0, 1],
                    Θ,
              [ 0, 0,
                       0, 0,
                              0, 0, 28, 0,
                                             0, 0],
                       0, 0, 1, 0, 0, 41, 0, 0],
              [ 0, 1, 0, 1, 0, 0, 0, 0, 34, 0],
              [ 0, 0, 0, 1, 1, 2, 0, 0, 1, 46]], dtype=int64)
In [41]: %matplotlib inline
        import matplotlib.pyplot as plt
        import seaborn as sn
        plt.figure(figsize=(10,7))
        sn.heatmap(cm, annot=True)
        plt.xlabel('Predicted')
        plt.ylabel('Truth')
Out[41]: Text(69.0, 0.5, 'Truth')
```



Exercise

Use famous iris flower dataset from sklearn.datasets to predict flower species using random forest classifier.

- 1. Measure prediction score using default n_estimators (10)
- 2. Now fine tune your model by changing number of trees in your classifer and tell me what best score you can get using how many trees